

量化方法理论结果 Survey

从“是否有可用 bound”到精确误差形式、假设与适用范围

基于 quantization-papers/ 中全文 Markdown 的逐篇整理

结论先行。在本组文献中，RaBitQ 与 Extended RaBitQ 最接近“可直接用于检索的理论保证”：它们同时给出无偏性、显式高概率 tail bound，并把误差写成维度和失败概率的函数。TurboQuant 给出很强的期望失真率和 matching lower bound，但论文主定理是期望 MSE/方差型保证，不能直接替代 sub-Gaussian tail。PQ、OPQ、CQ、SCANN、LVQ、SAQ、MRQ 都有有用的条件化误差分析；AQ、RQ、Revisiting AQ、LSQ+、NEQ 主要给出目标函数、单调性或几何解释，未证明同等级全局概率 bound。

1. 阅读口径与证据等级

本报告只统计原文实际陈述或证明的结果。这里的“没有 bound”特指：没有针对最终距离/内积估计或 ANN recall 的、对数据和查询统一的概率或 rate theorem；它不等于方法没有优化目标，也不等于方法在实验上无效。

对于单位向量 $o, q \in S^{d-1}$ ，记真实内积为 $s = \langle q, o \rangle$ ，估计量为 $\hat{s}$ ，误差为 $|\hat{s} - s|$ 。报告使用以下等级：

等级	含义
A	估计量保证：无偏性加显式高概率置信区间或 tail bound。
B	失真/率保证：期望 MSE、内积失真或信息论 lower bound。
C	条件化误差分析：依赖 Gaussian、均匀量化误差、固定任务或其他明确假设。
D	优化或经验结果：可有单调性/固定点/复杂度，但没有最终估计量的定量保证。

2. 总览矩阵

方法	等级	核心 bound	主要缺口
RaBitQ	A	无偏； $0(d^{(-1/2)})$ 高概率误差； $2 \exp(-c \epsilon^2)$ 失败概率。	没有 recall-at-k 或 codebook-learning theorem。
Extended RaBitQ	A/B	保持 RaBitQ tail； $B = \Theta(\log((\log(1/\delta))/(\epsilon^2)))$ 。	经验常数不是定理。
TurboQuant	B	$D_{mse} \leq (\sqrt{3\pi}/2) 4^{(-b)}$ ；无偏 $D_{prod} \leq \sqrt{3\pi} 4^{(-b)}$ ；matching lower bounds。	主结果是期望失真，没有直接 tail。
PQ	C	$MSDE \leq MSE$ ；SDC 有 $2 MSE$ 上界；cell-conditioned bias correction。	没有 rate、tail 或 recall theorem。
OPQ	B/C	Gaussian rate-distortion lower bound；块协方差的 AM-GM/Fischer 最优性。	依赖 source model；无搜索保证。
CQ	C	$ \tilde{d} - d \leq \ x - \bar{x}\ + \delta ^{(1/2)}$ 。	penalty relaxation、局部优化；无概率 bound。
SCANN/AVQ	C	score-aware loss 精确分解； $h_{parallel} \geq h_{perp}$ ；高维 η 极限。	无直接 MIPS recall/error theorem。
LVQ	C	图 pruning 等价条件；uniform error 下 ϵ 的 Gaussian 参数。	任务特定且包含经验“4 bit 安全”。

SAQ	C	继承 RaBitQ 的条件 bound; segment error 模型; Chebyshev segment bound。	有限轮 coordinate descent 和联合 bound 未证明。
MRQ	C	投影量化的 RaBitQ tail + PCA residual 的 Chebyshev bound。	没有 joint failure probability 或 recall theorem。
AQ/RQ/LSQ++/NEQ	D/C	目标函数、MSE 单调性或 norm/direction 几何结论。	没有可比较的全局概率 bound。

3. 逐篇理论结果

3.1. RaBitQ: 最接近示例中的定理形式

原文: [Gao_-_RaBitQ_Quantizing_High-Dimensional_Vectors_with_a.md](#)。等级: A。

RaBitQ 先中心化并把数据、查询归一化到单位球面,再用随机正交变换后的超立方体顶点量化数据向量 $\mathbf{o}$ 为 $|\langle \mathbf{o} \rangle$ 。估计器是

$$\hat{s} = \frac{\langle |\langle \mathbf{o} \rangle| \rangle}{q} (\langle |\langle \mathbf{o} \rangle, \mathbf{o} \rangle)$$

Theorem 3.2 给出

$$E[\hat{s}] = s$$

文中还给出 $E[|\langle \mathbf{o} \rangle, \mathbf{o} \rangle]$ 的精确 Gamma 函数表达式, 在 $d \in [10^2, 10^6]$ 内约为 0.8。因此在常见设置下, 误差是 $O(\frac{1}{\sqrt{d}})$, 而失败概率对 ϵ_0 呈二次指数衰减。令 $\epsilon_0 = \Theta(\sqrt{\log(\frac{1}{\delta})})$ 即可得到失败概率至多 δ 的置信半径。

论文还证明: 对查询向量做随机标量量化时, $B_q = \Theta(\log \log d)$ 足以使额外计算误差保持在 $O(\frac{1}{\sqrt{d}})$ 。这与主估计器 bound 分开计数。RaBitQ 的 bound 是 additive 的; 论文没有在不加归一化假设时给出统一 multiplicative bound, 也没有 recall-at-k 定理。

3.2. Extended RaBitQ: 把 bit/error trade-off 写成定理

原文: [Gao_et_al._-2025_-_ExtendRabitQ_Practical_and_Asymptotically_Optimal_Quantization_of_High-Dimensional_Vectors_in_Euclidean_Space_for.md](#)。等级: A B。

Extended RaBitQ 用随机旋转、平移后的整数网格, 并把每个维度扩展到 B bit。它保留 RaBitQ 的估计器和 Lemma 2.1:

$$E[\langle |\langle \mathbf{o} \rangle_0, \mathbf{q} \rangle| \langle \mathbf{o} \rangle_0, \mathbf{o} \rangle] = \langle \mathbf{o}, \mathbf{q} \rangle$$

$$|\hat{s} - s| \leq \sqrt{\frac{1 - \langle |\langle \mathbf{o} \rangle_0, \mathbf{o} \rangle|^2}{\langle |\langle \mathbf{o} \rangle_0, \mathbf{o} \rangle|^2}} * \frac{\epsilon_0}{\sqrt{d} - 1}$$

以至少 $1 - \exp(-c_0 \epsilon_0^2)$ 的概率成立。

Theorem 3.2 的主要结论是: 当 $\epsilon^{-2} \log(\frac{1}{\delta}) > d$ 时, 令

$$B = \Theta\left(\log\left(\left(\frac{1}{d}\right) * \frac{\log(\frac{1}{\delta})}{\epsilon^2}\right)\right)$$

即可保证绝对内积误差不超过 ϵ , 成功概率至少 $1 - \delta$ 。总码长为 Bd , 因此它把 bit/error trade-off 写成了对高维空间渐近最优的形式。文中另给出经验式: 在超过 99.9% 的样本上, $\epsilon < 5.75 * \frac{2^{-B}}{\sqrt{d}}$; 这个常数明确被标为 empirical formula, 不能与 theorem 混写。

3.3. TurboQuant: 期望失真很强, 但保证类型不同

原文: [Zandieh_等_-_2025_-_TurboQuant_Online_Vector_Quantization_with_Near-optimal_Distortion_Rate.md](#)。等级: B。

对单位范数输入, MSE 版本的 Theorem 1 为

$$D_{\text{mse}} = E \|\mathbf{x} - \tilde{\mathbf{x}}\|_2^2 \leq \left(\frac{\sqrt{3\pi}}{2}\right) * 4^{-b}$$

论文给出 $b = 1, 2, 3, 4$ 时约为 0.36, 0.117, 0.03, 0.009。证明先把随机旋转后的坐标归约为 Beta/spherical marginal, 再使用最优标量 Lloyd-Max 失真和 Panter-Dite 高分辨率式。

内积版本在 $(b - 1)$ bit MSE 量化后的 residual 上增加 1-bit QJL。Theorem 2 给出

$$E[\langle y, \tilde{x} \rangle] = \langle y, x \rangle,$$

$$D_{\text{prod}} \leq \frac{\sqrt{3}\pi^2 \|y\|_2^2}{d \cdot 4^b}.$$

论文给出的低 bit 数值为 $\frac{1.57}{d}, \frac{0.56}{d}, \frac{0.18}{d}, \frac{0.047}{d}$ 。Theorem 3 对任意 randomized quantizer 给出 lower bounds：存在 hard input 使 $D_{\text{mse}} \geq 4^{-b}$ ，并存在方向 y 使 $D_{\text{prod}} \geq \|y\|_2^2 / d^{4^b}$ 。所以 TurboQuant 的期望失真在常数因子内接近信息论下界。

注意保证类型：原文定理是 expected distortion/variance，不是 RaBitQ 那种直接的 sub-Gaussian tail。MSE 版本在一 bit 时有 $\frac{2}{\pi}$ 的内积 multiplicative bias，因此不能把其 MSE theorem 直接写成无偏 MIPS theorem。

3.4. PQ：有统计距离 bound，但无搜索概率保证

原文：Jégou_等_-2011-_Product_Quantization_for_Nearest_Neighbor_Search.md。等级：C。

对满足 Lloyd/Voronoi 条件的 quantizer，ADC 距离估计的 MSDE 满足

$$MSDE(q) \leq MSE(q)$$

这是统计期望 bound，不要求子空间独立，也没有 tail probability。原始 ADC 平方距离有向下 bias。条件化于量化 cell 并利用 centroid 条件，论文得到

$$E[(x - Y)^2 \mid q(Y) = c_i] = d(x, q(y))^2 + \xi(q, q(y))$$

PQ 的校正项是各个子量化器 cell distortion 的和；它对条件平方距离无偏，但论文实验指出用于排序时未校正估计往往更好。没有 codebook-learning rate、high-probability interval 或 recall-at-k theorem。

3.5. OPQ：Gaussian source 下的 rate-distortion 分析

原文：Ge_等_-Optimized_Product_Quantization.md。等级：B C。

若 $x \sim N(0, \Sigma)$ ，任意 k -codeword quantizer 的 rate-distortion lower bound 为

$$E \geq k^{-\frac{2}{D}} D |\Sigma|^{\frac{1}{D}}.$$

对有 M 个 block 的 PQ/OPQ，令 $\hat{\Sigma} = R \Sigma R^T$ ，块为 $\hat{\Sigma}_{mm}$ ，则

$$E(R) \geq k^{-2\frac{M}{D}} \left(\frac{D}{M}\right) \sum_m |\hat{\Sigma}_{mm}|^{\frac{M}{D}}.$$

AM-GM 与 Fischer inequality 给出

$$\sum_m |\hat{\Sigma}_{mm}|^{\frac{M}{D}} \geq M |\Sigma|^{\frac{1}{D}}.$$

当 PCA 使子空间独立且各块 determinant 平衡时可达到下界；Eigenvalue Allocation 是这个平衡分块的贪心实现。该结果依赖 Gaussian source model，属于 distortion optimality，不是 distribution-free 的 ANN guarantee。

3.6. CQ：确定性的距离上界

原文：Zhang_等_-CQ_Composite_Quantization_for_Approximate_Nearest_Neighbor_Search.md。等级：C。

对 $\text{bar}(\mathbf{x}) = \sum_m \mathbf{c}_m(\mathbf{x})$ ，令 cross-dictionary term 为 δ ，并令 $\hat{d}(q, x) = \sqrt{\|q - x\|_2^2 + (M - 1)\|q\|_2^2}$ 。Theorem 1 是

$$|\tilde{d}(q, |(x)) - \hat{d}(q, x)| \leq \|x - |(x)\|_2 + |\delta|^{\frac{1}{2}}.$$

若 cross term 对所有数据向量严格为常数 ϵ ，可把学习问题看作最小化该上界；实现中的 penalty relaxation 只近似满足约束。交替算法的非负目标单调不增并趋于 fixed point，但没有 convergence rate、global-optimum、概率距离 bound 或 recall theorem。

3.7. SCANN/Anisotropic VQ：对 MIPS loss 的精确分解

原文：Guo_等_-2020-_SCANN_Accelerating_Large-Scale_Inference_with_Anisotropic_Vector_Quantization.md。等级：C。

对均匀球面 query，score-aware loss 精确分解为

$$\ell(x, \tilde{x}, w) = h_{\text{parallel}(w, \|x\|)} \|r_{\text{parallel}}\|_2^2 + h_{\text{perp}(w, \|x\|)} \|r_{\text{perp}}\|_2^2$$

其中

$$h_{\text{parallel}} = (d - 1) \int_0^\pi w(\|x\| \cos(\theta)) (\sin^{d-2}(\theta) - \sin^{d(\theta)}) d\theta,$$

$$h_{\text{perp}} = \int_0^\pi w(\|x\| \cos(\theta)) \sin^d(\theta) d\theta.$$

若 $w(t)$ 在非负区间单调不减且负区间为零，Theorem 3.3 证明 $h_{\text{parallel}} \geq h_{\text{perp}}$ 。阈值权重的高维极限为

$$\lim_{d \rightarrow \infty} \frac{\eta}{d-1} = \frac{\left(\frac{\|x\|}{\|x\|}\right)^2}{1 - \left(\frac{\|x\|}{\|x\|}\right)^2}, \quad \eta = \frac{h_{\text{parallel}}}{h_{\text{perp}}}.$$

Theorem 4.2 还给出固定 assignment 时的 closed-form codeword update；有限 assignment 加上每步降目标意味着收敛到 fixed point。论文没有直接的 MIPS error、recall 或 tail theorem。

3.8. LVQ：图构建任务中的条件化误差模型

原文：Aguerrebere_等_-2023-_LVQ_Similarity_Search_in_the_Blink_of_an_Eye_with_Comp.md。等级：C。

在 Euclidean pruning、 $\alpha = 1$ 时，Proposition 1 说明 full-precision 与 LVQ pruning 决策在下列条件下等价：

$$|a^T x' - b| \|x - x^*\| \geq |E|.$$

在 uniform scalar-quantization error 假设下，Proposition 2 将 E 建模为 Gaussian，均值为

$$\mu_E = \frac{d}{24} (\Delta_x^2 - \Delta_{x^*}^2)$$

方差为

$$\sigma_E^2 = \frac{\Delta_x^2}{12} \|x' - x\|^2 + \frac{\Delta_{x^*}^2}{12} \|x' - x^*\|^2 + \frac{\Delta_{x'}^2}{12} \|x - x^*\|^2 \\ + \frac{d(\Delta_x^4 + \Delta_{x^*}^4)}{720} + d\Delta_x^2 \frac{\Delta_x^2 + \Delta_{x^*}^2}{144}.$$

Corollary 1 给出 $|E|$ 的 folded-normal 参数。论文的“LVQ-4 通常安全、LVQ-2 无 guarantees”来自经验 error bands，不是通用 bit-rate theorem；也没有一般 LVQ distance/recall bound。

3.9. RQ：残差 MSE 逐阶段单调

原文：Chen_等_-2010-_RQ_Approximate_Nearest_Neighbor_Search_by_Residual_Vector_Quantization.md。等级：D C。

每个 residual stage 用 k-means centroid 最小化 cluster 内平方误差，因此

$$MSE(Q_i) \leq MSE(Q_{i-1})$$

这是全文中最明确的定量性质。论文也给出 asymmetric distance 的 lookup 展开式和 coarse-to-fine 检索，但没有 L, K, d 的 distortion rate、high-probability error 或 recall theorem。

3.10. AQ：全连接 MRF，主要是优化框架

原文：Babenko 和 Lempitsky_-AQ_Additive_Quantization_for_Extreme_Vector_Compression.md。等级：D。

AQ 的 coding objective 是

$$E(i_1, \dots, i_M) = \|x - \sum_m c^{m(i_m)}\|_2^2$$

可展开成 unary 与 pairwise terms 的 fully connected discrete MRF。论文给出 lookup-table 距离/内积、beam search 和 block-coordinate codebook update，但明确指出 exact encoding 是 hard combinatorial problem。没有按 bit 给出的 coding-error rate、无偏性、tail 或 search guarantee。

3.11. Revisiting AQ：ILS 改进但没有 theory bound

原文：Martinez_等_-2016-_Revisiting_Additive_Quantization.md。等级：D。

论文继续优化 $\min \|X - CB\|_F^2$ ，把 AQ encoding 视为一般情况下 NP-hard 的 MAP inference，并用 iterated local search 加速 ICM。作者明确说明 stochastic local search 的 theoretical performance 难以分析，全文以 empirical benchmark 为主；没有 coding-error rate、tail、无偏性或 recall theorem。

3.12. LSQ++：精确子问题更新，不等于最终保证

原文：Martinez_等_-LSQ++_Lower_running_time_and_higher_recall_in_multi-codebook_quantization.md。等级：D。

LSQ++ 的核心目标仍是 $\min \|X - CB\|_F^2$ 。固定 codes 时，regularized codebook subproblem 的 closed form 为

$$C = XB^T(BB^T + \lambda I)^{-1}.$$

该式是优化子问题的精确解；stochastic relaxation 是 simulated annealing 的启发式近似。论文没有 distribution-free distortion rate、估计器 tail、无偏性或 recall theorem。

3.13. NEQ: norm/direction 几何解释

原文: [Norm-explicit-quantization.md](#)。等级: C D。

NEQ 将 MIPS 误差分为 norm error 和 angular error。若方向完全准确，只有 norm 误差时相对内积误差精确满足 $u = \gamma$ 。Theorem 1 给出：在原文定义的 α, β, t 角度区间条件下，方向误差造成的相对内积误差不超过 angular error。随后分别量化 relative norm 与 unit direction，但没有证明 norm codebook 的 rate、distribution-free MIPS bound 或 recall theorem；主要证据是几何 theorem 加实验。

3.14. SAQ: 继承 RaBitQ，但附加部分仍是条件化

原文: [Li 等 - 2025 - SAQ Pushing the Limits of Vector Quantization through Code Adjustment and Dimension Segmentation](#)

等级: C。

Lemma 2.1 重述 RaBitQ 的无偏性与置信区间。Lemma 3.1 证明 CAQ 的 coordinate-adjustment codebook 与 Extended RaBitQ grid 等价。因此，如果 coordinate descent 达到该 codebook 上的 global cosine maximizer，CAQ 可继承 RaBitQ bound；论文明确承认有限轮 coordinate descent 不一定达到最优，误差相同主要是 empirical observation。

分段规划使用模型

$$\text{ERROR}(\text{Seg}, B) = \frac{2^{-B}}{\pi} \sum_{i \in S} \sigma_i^2$$

在该模型和给定 bit quota 下，dynamic programming 对规划本身求得 exact optimum。对 segment inner product, $\sigma_{\text{Seg}}^2 = \sum_{i \in S} q_i^2 \sigma_i^2$, Chebyshev 给出

$$P\{|\langle o_S, q_S \rangle| \geq m \sigma_{\text{Seg}}\} \leq \frac{1}{m^2}.$$

这不是整个 SAQ 的联合 tail theorem，也不能把“误差不大于 RaBitQ”理解成已证明的 finite-iteration、distribution-free 结论。

3.15. MRQ: 投影部分有 tail，残差部分用 Chebyshev

原文: [Yang 等 - 2026 - MRQ Quantization Meets Projection A Happy Marriage for Approximate k-Nearest Neighbor Search](#)。等级: C。

PCA 将距离精确拆成 projected 与 residual 两部分。projected inner product 使用 RaBitQ-style interval，原文 Equation (5) 的失败概率是 $2 \exp(-c_0 \varepsilon_0^2)$ 。对中心化数据，residual inner product 的方差为

$$\sigma^2 = \sum_{i=d+1}^D q_i^2 \sigma_i^2$$

并由 Chebyshev 得到 $P\{|\langle x_r, q_r \rangle| \geq m \sigma\} \leq \frac{1}{m^2}$ 。实现中将两个半径加到 pruning rule 上。这里没有 joint failure probability、PCA/truncation bias theorem 或 end-to-end recall guarantee；原文非正式 estimator display 中的 denominator 有 typo，理论 intended denominator 是 stored alignment $\langle \tilde{x}, x \rangle$ 。

3.16. RaBitQ-TurboQuant 比较 note

原文: [compare-rabitq-turboq.md](#)。它不是新方法，但为本报告做理论交叉核对。该 note 重申 Alon-Klartag 的高精度 trade-off：在适用 regime 中

$$B = \Theta\left(\log\left(\left(\frac{1}{d}\right) * \frac{\log(\frac{1}{\delta})}{\varepsilon^2}\right)\right)$$

即对失败概率表现为 $\log \log(\frac{1}{\delta})$ 级别；TurboQuant 的期望/variance guarantee 若只用 Chebyshev 转成 tail，则为较弱的 $\log(\frac{1}{\delta})$ 依赖。该 note 的实验复现结论不作为本报告的 theorem evidence。

4. 横向结论：哪些方法真的“类似示例定理”

4.1. 最强的 estimator-level guarantee

RaBitQ 给出“无偏性 + 明确 confidence interval + $O(d^{-\frac{1}{2}})$ tail”，而 Extended RaBitQ 在此基础上给出 bit/error 的渐近最优 trade-off。它们是最接近示例中“Theorem + proof sketch + high probability”结构的两组结果。

4.2. 最强的 expected-distortion guarantee

TurboQuant 给出 4^{-b} 级别的期望 MSE 和无偏内积失真，并给出相同数量级的 lower bound。这一结果非常强，但它与 RaBitQ 的 tail guarantee 属于不同评价维度，不能直接把 expected MSE 改写成 high-probability bound。

4.3. 经典 VQ 的理论位置

PQ/OPQ 有 MSE 或 source-model distortion 不等式；CQ 有 deterministic distance upper bound；SCANN 有 score-aware loss 分解；LVQ 有 graph-pruning 的条件化概率模型。这些结果能解释误差来源，但都没有直接给出“给定 bit 数即可保证 recall-at-k”的定理。

4.4. 后续混合方法的边界

SAQ 和 MRQ 复用 RaBitQ 的核心组件，因此可以继承一部分 bound；但 coordinate descent 的有限迭代、PCA 分段、residual omission 和误差合并都引入额外假设。对它们最稳妥的表述是“带条件的 inherited/segment-level guarantee”，而不是新的 end-to-end theorem。

4.5. 启发式 MCQ 家族

AQ、RQ、Revisiting AQ、LSQ++、NEQ 的论文贡献主要在建模、优化、复杂度或几何解释；其中 RQ 至少有 residual MSE 的逐阶段单调性，但没有类似 RaBitQ 的统一概率误差 bound。

5. 证据边界与写作建议

- 把“无偏”“期望失真”“高概率 tail”“确定性上界”“经验公式”分开写，不能互换。
- 把 source-model 假设（Gaussian、均匀量化误差、query/data 同分布、中心化）紧跟在公式后面。
- 把 estimator bound 与 search guarantee 分开：即便距离估计有置信区间，ANN recall 还会受 IVF 候选覆盖、重排策略和近邻间隔影响。
- 对 SAQ/MRQ/LVQ 说明 inherited、conditional 或 empirical 的性质；对 AQ/RQ/LSQ++/NEQ 明确写“未提供同等级的全局概率 bound”。

6. 原文阅读清单

本报告逐篇处理以下 16 个 Markdown 文件：

- Aguerrebere_等_-_2023_-_LVQ_Similarity_Search_in_the_Blink_of_an_Eye_with_Comp.md
- Babenko和Lempitsky_-_AQ_Additive_Quantization_for_Extreme_Vector_Compression.md
- Chen_等_-_2010_-_RQ_Approximate_Nearest_Neighbor_Search_by_Residual_Vector_Quantization.md
- compare-rabitq-turboq.md
- Gao_-_RaBitQ_Quantizing_High-Dimensional_Vectors_with_a.md
- Gao_et_al.__-_2025_-_ExtendRabitQ_Practical_and_Asymptotically_Optimal_Quantization_of_High-Dimensional_Vectors_in_Euclidean_Space_for.md
- Ge_等_-_Optimized_Product_Quantization.md
- Guo_等_-_2020_-_SCANN_Accelerating_Large-Scale_Inference_with_Anisotropic_Vector_Quantization.md
- Jégou_等_-_2011_-_Product_Quantization_for_Nearest_Neighbor_Search.md
- Li_等_-_2025_-_SAQ_Pushing_the_Limits_of_Vector_Quantization_through_Code_Adjustment_and_Dimension_Segmentati
- Martinez_等_-_2016_-_Revisiting_Additive_Quantization.md
- Martinez_等_-_LSQ++_Lower_running_time_and_higher_recall_in_multi-codebook_quantization.md
- Norm-explicit-quantization.md
- Yang_等_____2026_-_MRQ_Quantization_Meets_Projection_A_Happy_Marriage_for_Approximate_k-Nearest_Neighbor_Search.md
- Zandieh_等_-_2025_-_TurboQuant_Online_Vector_Quantization_with_Near-optimal_Distortion_Rate.md
- Zhang_等_-_CQ_Composite_Quantization_for_Approximate_Nearest_Neighbor_Search.md

报告没有修改 main.tex、appendix.tex 或其他论文正文文件。